

Estudio Comparativo de Algoritmos para el Problema del Bandido Multibrazo

[AAPGAG] Alejandro Alonso Puig, Pablo Guillén Marquina, Andrés García Meroño

9 de marzo de 2025

Resumen

En este documento se presenta la resolución de la Práctica 1 de la asignatura, correspondiente al problema del Bandido de los k-brazos, comparando su rendimiento en entornos estacionarios.

Para ello se han implementado varias familias de métodos: ϵ -greedy, UCB, ascenso del gradiente, evaluando las recompensas y rechazos acumulados. Concretamente, queremos valorar los mejores algoritmos capaces de encontrar el mejor equilibrio entre exploración-explotación.

A lo largo del documento comentaremos tanto los algoritmos implementados como los resultados obtenidos durante su estudio. Los experimentos fueron organizados en notebooks independientes para cada enfoque, facilitando su ejecución y análisis desde un *main.ipynb* con acceso a Google Colab. El repositorio se encuentra en el siguiente [enlace](#).

1. Introducción

El problema del **bandido multi-brazo** es un modelo fundamental en aprendizaje por refuerzo, donde un agente debe elegir repetidamente entre varias opciones sin conocer de antemano sus recompensas. El desafío radica en equilibrar **exploración** (adquirir información sobre los brazos) y **explotación** (maximizar la recompensa acumulada).

Para ello se implementan varias familias de métodos:

- **ϵ -Greedy**: Selección basada en recompensa estimada con exploración controlada
- **Upper Confidence Bound (UCB)**: Uso de confianza estadística para balancear exploración.
- **Ascenso del Gradiente**: Softmax y Gradiente de Preferencias para actualización probabilística.
- **Métodos Bayesianos**: Muestreo de Thompson y UCB Bayesiano con modelado de incertidumbre.

Los algoritmos se evaluaron con distintas distribuciones de brazos (Bernoulli, Binomial, Normal y Beta), midiendo cuatro métricas:

- **Recompensa promedio**: Mide la eficacia del algoritmo en la maximización de ganancias.
- **Porcentaje de selección del brazo óptimo**: Indica la capacidad del algoritmo para identificar y explotar la mejor opción.
- **Regret acumulado**: Representa la pérdida de recompensa en comparación con una estrategia ideal.

- **Estadísticas de selección de los brazos**: Analiza la distribución de selecciones entre todos los brazos disponibles.

Estos experimentos permiten comparar la eficiencia de cada estrategia y el impacto de sus hiperparámetros en la convergencia y estabilidad del aprendizaje.

2. Algoritmos

De entre los algoritmos vistos en clase [2], hemos realizado la implementación de ellos, cuya estructura se refleja en la Figura 1. Concretamente, se ha implementado lo siguiente:

- **7 algoritmos de decisión**: `epsilon_greedy`, `preference_gradient`, `softmax`, `thomson_sampling`, `bayesian_ucb`, `ucb1` y `ucb2`
- **4 distribuciones para los brazos**: Bernoulli, beta, binomial y normal.
- **4 gráficas de recompensa promedio**, selección de brazo óptimo, estadísticas de brazos y *regret* acumulado.
- **4 estudios en notebook**: ϵ -Greedy, UCB1, UCB2, ascenso de Gradiente (Softmax y Gradiente de preferencias) y métodos Bayesianos (muestreo de Thompson y UCB Bayesiano).

Cada algoritmo se evaluó con diferentes distribuciones de recompensa (*Bernoulli*, *Binomial*, *Normal* y *Beta*), adaptando su estrategia de exploración y explotación según las características de cada entorno.

3. Metodología

Para evaluar los algoritmos implementados, se diseñaron experimentos con un problema de k-bandit, utilizando diferentes distribuciones de recompensa (Bernoulli, Binomial, Normal y Beta). Se fijaron parámetros clave, como el número de brazos ($k=10$), el número de pasos por experimento (1000) y el número de ejecuciones (500), garantizando estabilidad estadística.

Cada experimento analizó cuatro métricas principales:

- **Recompensa Promedio vs Pasos**: Indica la eficiencia de cada algoritmo en la maximización de la recompensa acumulada.
- **Porcentaje de Selección del Brazo Óptimo**: Mide la capacidad del algoritmo para identificar y explotar la mejor opción.
- **Distribución de Selección de Brazos**: Representa




Figura 1: Estructura del directorio de trabajo

qué brazos fueron explorados y con qué frecuencia.

- **Evolución del Regret:** Evalúa el costo de no haber seleccionado siempre el brazo óptimo.

Los experimentos fueron organizados en notebooks independientes para cada enfoque, facilitando su ejecución y análisis desde un *main.ipynb* con acceso a Google Colab.

4. Evaluación/Experimentos

En este apartado desglosaremos en subsecciones los resultados obtenidos para los algoritmos estudiados.

4.1. ϵ -Greedy

Con valores bajos de ϵ , la exploración fue limitada, favoreciendo una rápida convergencia al brazo óptimo. Valores más altos permitieron una mejor exploración, pero con menor estabilidad en la recompensa. La comparativa de gráficas se puede observar en la Figura 2.

Exploración vs Explotación:

- $\epsilon = 0$ (**Greedy puro**): no explora en absoluto y se queda atrapado en la primera opción.
- $\epsilon = 0,01$: explota muy poco, mejorando lentamente con el tiempo.
- $\epsilon = 0,1$: encuentra rápidamente el mejor brazo y lo explota eficientemente.

Selección del Brazo Óptimo:


- $\epsilon = 0,01$: el brazo óptimo se selecciona el 60 % del tiempo.
- $\epsilon = 0,1$: el brazo óptimo se selecciona el 80 % del tiempo.

Regret Acumulado:

- $\epsilon = 0$: tiene el peor desempeño, con un *regret* en cons-

tante crecimiento.

- $\epsilon = 0,1$: minimiza el *regret* rápidamente, estabilizándose en el menor valor.

Figura 2: Gráficas de la evaluación del algoritmo ϵ -greedy para distintos valores de ϵ

Conclusión: El valor de $\epsilon = 0,1$ logra el mejor equilibrio entre exploración y explotación, permitiendo encontrar el mejor brazo rápidamente y maximizando la recompensa a largo plazo.

4.2. UCB (Upper Confidence Bound)

UCB1 mostró un equilibrio entre exploración y explotación, mientras que UCB2 realizó exploraciones más agresivas, resultando en una convergencia más tardía. La comparativa de gráficas se puede observar en la Figura 3.

Exploración y Estabilización:

- **UCB2:** explora al inicio, obteniendo una mayor recompensa en las primeras etapas.
- **UCB1:** se estabiliza antes, logrando un porcentaje de selección óptima más alto en el largo plazo.

Selección del Brazo Óptimo:

- Ambos algoritmos identifican correctamente el brazo 7 como el óptimo.
- **UCB1** lo selecciona con más frecuencia en el largo plazo (99 %).
- **UCB2** mantiene una exploración residual (~ 93 %).

Regret Acumulado:

- **UCB1** minimiza mejor el *regret*, ya que reduce la exploración tras identificar el mejor brazo.
- **UCB2** mantiene un *regret* creciente, debido a su estrategia de exploración en fases más largas.

Conclusión: **UCB2** explora mejor al inicio, lo que puede ser útil cuando hay mucha incertidumbre, pero **UCB1** logra un mejor rendimiento final al centrarse en la explotación del mejor brazo.

4.3. Métodos de Gradiente

Softmax y *Preference Gradient* tuvieron una fase inicial de mayor exploración. Ajustando adecuadamente τ y α , se pudo mejorar la estabilidad en la selección del brazo óptimo. La




Figura 3: Gráficas de la evaluación del algoritmo UCB

comparativa de gráficas se puede observar en la Figura 4.

Rendimiento General:

- **PreferenceGradient** ($\alpha = 1,0$): aprende mejor y alcanza mayor recompensa ($\sim 0,88$).
- **Softmax** ($\tau = 1,5$): sigue explorando y se mantiene en valores más bajo ($\sim 0,73$).

Selección del Brazo Óptimo:

- **PreferenceGradient**: converge mejor, seleccionando el brazo óptimo en más del 50 % de los casos.
- **Softmax**: mantiene una exploración constante, lo que reduce su tasa de selección óptima ($\sim 20\%$).

Regret Acumulado:

- **PreferenceGradient**: minimiza mejor el *regret*, indicando que toma decisiones más óptimas con el tiempo.
- **Softmax**: tarda en converger, lo que aumenta su *regret* debido a exploración prolongada.




Figura 4: Gráficas de la evaluación del algoritmo del método del gradiente

Conclusión: En este experimento, **PreferenceGradient** es superior en la identificación y explotación del mejor brazo, mientras que **Softmax** sigue explorando demasiado y no logra optimizar la selección óptima.

4.4. Métodos Bayesianos

Thompson Sampling demostró ser eficiente al modelar la incertidumbre mediante distribuciones Beta, logrando un buen

balance exploración-explotación. *Bayesian UCB*, con un ajuste adecuado de γ , permitió una exploración más estructurada, aunque en algunos casos mostró sesgo hacia ciertos brazos. La comparativa de gráficas se puede observar en la Figura 5.

Rendimiento General:

- **Thompson Sampling**: mejora progresivamente, partiendo de una recompensa baja y alcanzando valores $\sim 0,70$.
- **Bayesian UCB**: mantiene recompensas estables desde inicio ($\sim 0,67 - 0,69$), favoreciendo la explotación temprana.

Selección del Brazo Óptimo:

- **Thompson Sampling**: requiere más exploración inicial, pero eventualmente alcanza niveles similares ($\sim 93\%$).
- **Bayesian UCB**: selecciona el brazo óptimo rápidamente ($\sim 90\%$) y se mantiene estable.

Regret Acumulado:

- **Thompson Sampling**: explora más, acumulando mayor *regret* inicialmente, pero mejora con el tiempo.
- **Bayesian UCB**: minimiza el *regret* rápidamente, aprovechando el mejor brazo desde temprano.




Figura 5: Gráficas de la evaluación de los métodos bayesianos

Conclusión: **Bayesian UCB** es más eficiente si se busca explotar rápido el mejor brazo, pero sugiere ajustar γ para permitir más exploración en problemas con mayor incertidumbre. **Thompson Sampling**, en cambio, aprende más progresivamente, lo que puede ser beneficioso en entornos dinámicos o desconocidos.

Cierto es que en la gráfica de *regret*, Figura 6, pareciera haber una tendencia de mantener un crecimiento paralelo en ambas, por lo que, por sugerencia del profesor, hemos extendido a 4000 pasos en el tiempo, observando que dicho paralelismo no es tal y Thompson tiende a estabilizarse.

5. Conclusiones

El estudio comparativo de los diferentes enfoques para el problema del *Multi-Armed Bandit* ha demostrado que no existe un único algoritmo óptimo para todos los casos. La elección del método depende de la naturaleza del problema y de la distribución de las recompensas.




Figura 6: Comparación del *regret* acumulado en los métodos bayesianos estudiados

Conclusiones principales:

- ▶ **ϵ -Greedy** es una estrategia simple pero efectiva, con un buen desempeño si se ajusta correctamente ϵ .
- ▶ **UCB** ofrece una solución más estructurada que favorece una mejor exploración sin necesidad de un parámetro adicional.
- ▶ **Métodos de Gradiente** son más sensibles a la elección de hiperparámetros, pero pueden adaptarse mejor en entornos dinámicos.
- ▶ **Métodos Bayesianos** permiten una exploración más fundamentada en la incertidumbre, con **Thompson Sampling** destacándose por su equilibrio exploración-explotación.

Líneas futuras de trabajo:

- ▶ Optimización de hiperparámetros mediante *Grid Search* o *Bayesian Optimization*.
- ▶ Extensión del estudio a entornos no estacionarios donde las recompensas cambian con el tiempo.
- ▶ Aplicación de estos algoritmos en problemas reales como sistemas de recomendación o asignación dinámica de recursos.

Referencias

- [1] Sutton, R. S., & Barto, A. G. (2018). Reinforcement Learning: An Introduction (2nd ed.). MIT Press.
- [2] Hernandez Molinero, Luis D. (2025). *Aprendizaje por Refuerzo Bandido Multibrazo*. Máster en Inteligencia Artificial. Universidad de Murcia
- [3] Lattimore, T., & Szepesvári, C. (2020). Bandit Algorithms. Cambridge University Press.
- [4] Auer, P., Cesa-Bianchi, N., & Fischer, P. (2002). Finite-time Analysis of the Multiarmed Bandit Problem. *Machine Learning*, 47(2-3), 235-256.
- [5] Van Roy, B., & Russo, D. (2014). Learning to Optimize via Information-Directed Sampling. *Advances in Neural Information Processing Systems (NeurIPS)*.
- [6] Documentación oficial de *NumPy*. <https://numpy.org/doc/stable/>
- [7] Documentación oficial de *SciPy*. <https://docs.scipy.org/doc/scipy/reference/stats.html>